Teoría de la Información

Fuentes de Información



Universidad de Valladolid

Técnicas de Aprendizaje Automático

Grado de Ingeniería Informática
Doble Grado con Estadística (INDAT)
Departamento de Informática (ATC, CCIA y LSI)

Transmisión de la Información I

Tiempo Oviedo	Probabilidad	Código A
Soleado	1/4	00
Nublado	1/4	01
Lluvia	1/4	10
Niebla	1/4	11

Longitud media por mensaje:

L= 2 binits/mensaje

bit: unidad de información
Binit: dígito binario

Transmisión de la Información II

Tiempo Almería	Probabilidad	Código A	Código B
Soleado	1/4	00	10
Nublado	1/8	01	110
Lluvia	1/8	10	111
Bruma	1/2	11	0

$$L = 2P(S) + 3P(N) + 3P(L) + 1P(B) = \frac{14}{8} \, binits/mensaje$$

Ahorro: 0.25 binits/mensaje
Ganancia: 12.5%

Ejercicio 1

- Basado en la codificación anterior, se recibe esta tira de bit:

  0001010010010101110

- Descodificar y calcular la longitud media de estos mensajes expresados en binits.
- Compare esta cantidad con la medida en la dispositiva anterior e intente explicar la diferencia

Solución

- 00010100100101011110
- 0-0-0-10-10-0-10-0-10-10-111-0

- Bruma, bruma, bruma, soleado, soleado, bruma, soleado, bruma, soleado, bruma,, bruma, lluvia, bruma

- L=19/12=1,5833 binits/mensaje

- L(media)=14/8= 1,75 binits/mensaje

- Las probabilidades a priori no se verifican en esta muestra tan pequeña de mensajes.

Cantidad de Información

- Cantidad de información asociada a un suceso E.

$$I(E)=\log_a \frac{1}{P(E)}$$

$$P(E)\uparrow \Leftrightarrow I(E)\downarrow$$

- Si el código es binario, se elije la base 2 del log

- I(E) se expresa en bits.

$$\left\{ \begin{array}{l} I(niebla-Oviedo)=\log_2 \frac{1}{2^{-2}}=2\,bits \\ I(bruma-Almería)=\log_2 \frac{1}{2^{-1}}=1\,bit \end{array} \right\}$$

Fuente de Información sin memoria

$S = \{s_1, s_2, s_3, \ldots \ldots s_q\} \longrightarrow s_i, s_j, \ldots \ldots$ $\qquad I(s_i) = log \frac{1}{P(s_i)}$

Hipótesis de Memoria Nula $\Leftrightarrow P(s_i / s_j) = P(s_i) \quad \forall\, i, j = 1,2,\ldots q \ (i \neq j)$

Cantidad de información media asociada a la fuente.

$$\sum_{i=1}^{q} P(s_i) I(s_i) = H(S)$$

Def: ***Entropía*** *asociada a la fuente*

Entropía

$$S(Oviedo) = \{soleado, nublado, lluvia, niebla\} \implies H(S) = 2\ bits$$

$$S(Almeria) = \{soleado, nublado, lluvia, bruma\}$$

$$H(S) = \frac{1}{4}2 + \frac{1}{8}3 + \frac{1}{8}3 + \frac{1}{2}1 = \frac{14}{8}\ bits$$

Coincide con la longitud media de los mensajes en este caso particular, pero esto no se puede generalizar (*)

Cuanto más entropía, más uniforme la distribución de los mensajes.

$$S = \{c_1, c_2, \dots c_n\} \implies H(S) = \sum_{i=1}^{n} P(c_i)I(c_i)$$

(*) *H(S)* no depende de la codificación, pero sí de la probabilidad a priopri

Ejercicio

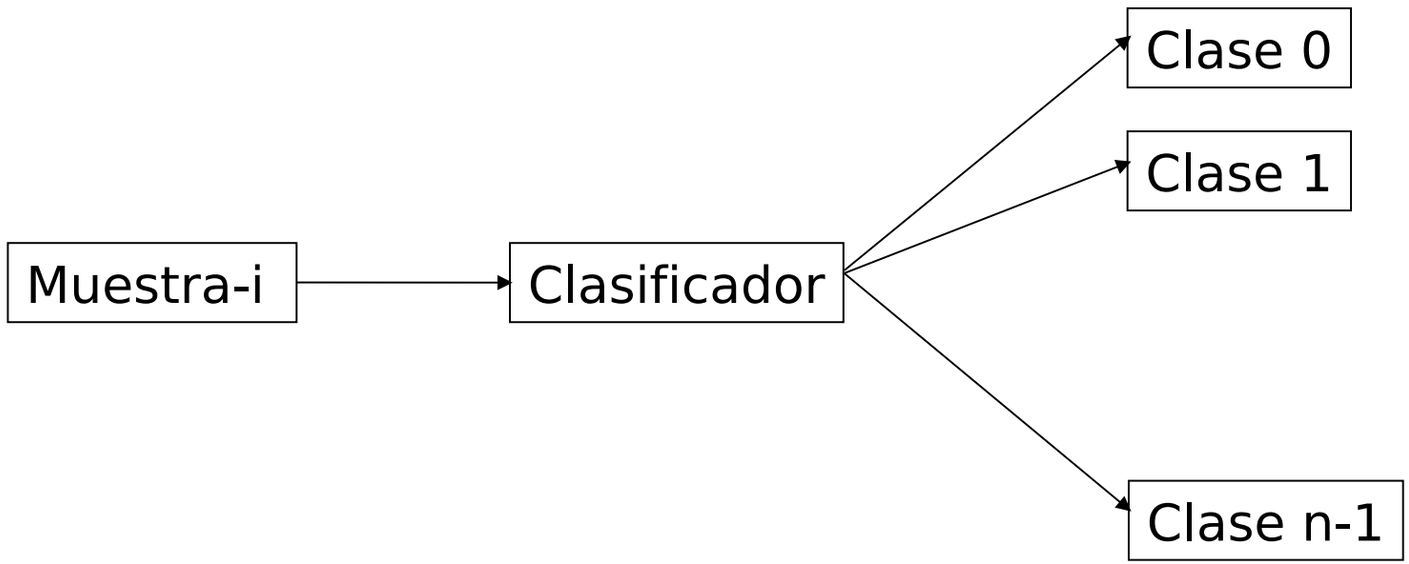
- Demostrar que una fuente con q mensajes equiprobables tiene una entropía de:

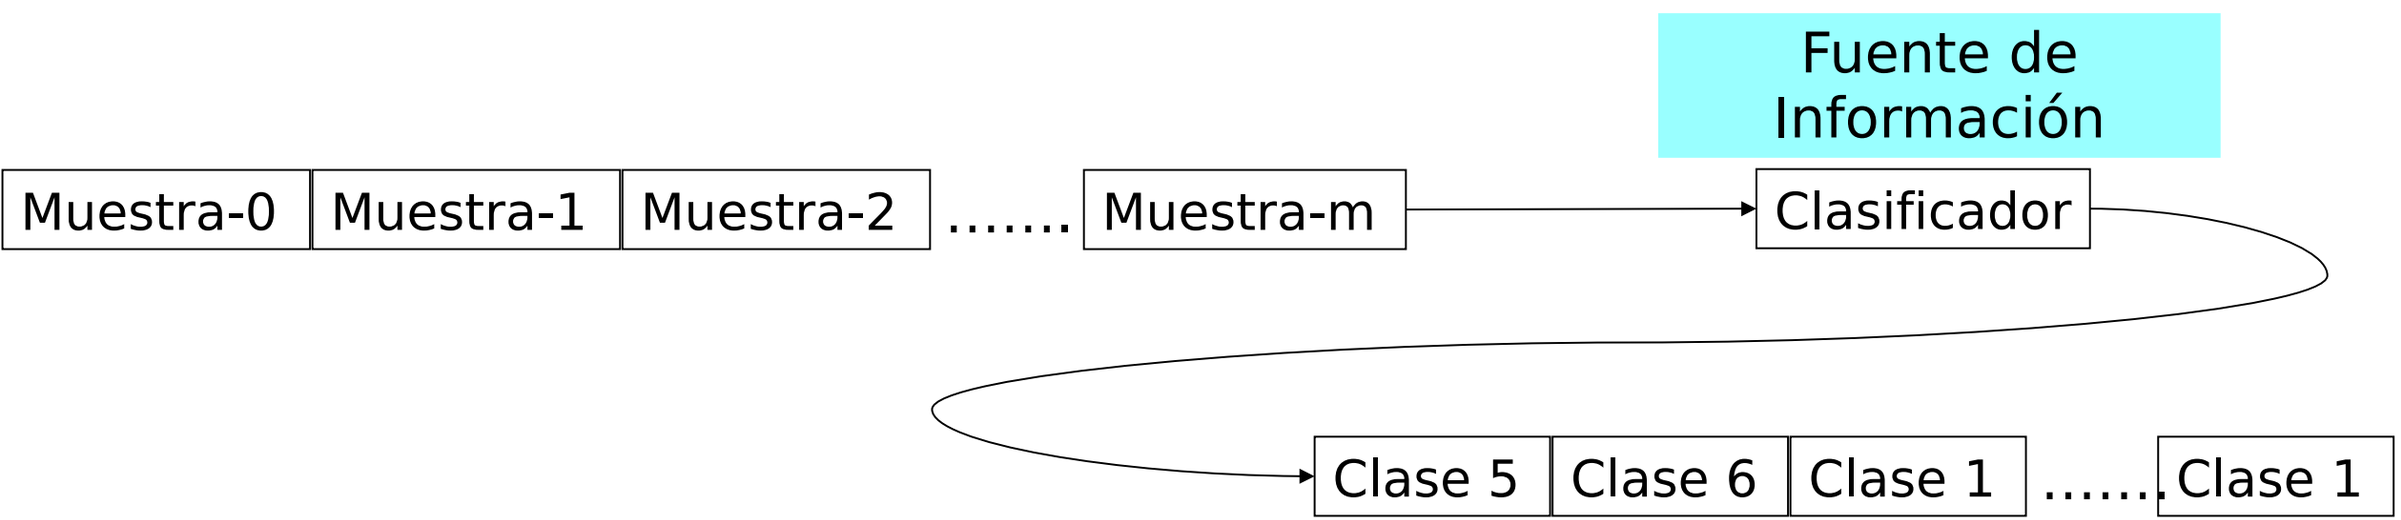
$$H(S) = \log_2 q$$

- Es el máximo desorden, porque cualquier otra distribución de probabilidades ofrecería una entropía menor

- Una fuente binaria tendría entropía 1, si ambos mensaje fueran totalmente aleatorios.

Clasificación





Clasificador como Fuente de Información

- En la salida del clasificador será:
  - Colección de etiquetas posibles: $S=\{c_1, c_2, ... c_n\}$
  - Entropía asociada al clasificador: $H(S)=\sum_{i=1}^{n} P(c_i) I(c_i)$
- Cada muestra x lleva asociada su etiqueta c(x)
- Habrá experimentos donde todas las clases tienen el mismo número de muestras (equiprobables) pero, en general, no tiene por qué ser así.

Ejemplo de clasificador y entropía

- Se tiene tabulada una serie de muestras, una por fila, cada una de las cuales viene dada por cuatro atributos (características) y una clase (Play Tennis)

Outlook	Temperature	Humidity	Wind	PlayTennis
Sunny	Hot	High	Weak	NO
Sunny	Hot	High	Strong	NO
Overcast	Hot	High	Weak	YES
Rain	Mild	High	Weak	YES
Rain	Cool	Normal	Weak	YES
Rain	Cool	Normal	Strong	NO
Overcast	Cool	Normal	Strong	YES
Sunny	Mild	High	Weak	NO
Sunny	Cool	Normal	Weak	YES
Rain	Mild	Normal	Weak	YES
Sunny	Mild	Normal	Strong	YES
Overcast	Mild	High	Strong	YES
Overcast	Hot	Normal	Weak	YES
Rain	Mild	High	Strong	NO

- Calcular la entropía del clasificador

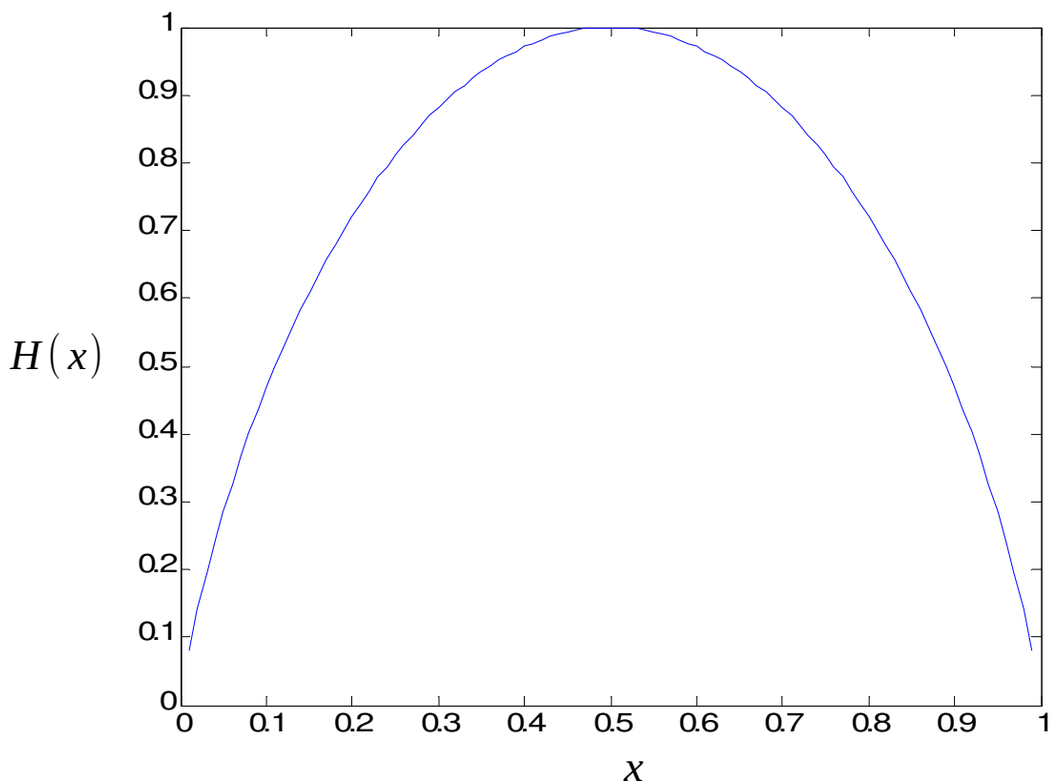
Solución

Clase	Probabilidad	I(c)
No	5/14	$\log_2(14/5)=1,4854$
Yes	9/14	$\log_2(14/9)=0,6734$
H(S)		0,940286 bits

Entropía de un Clasificador Binario

$$H(S_{binario}) = P(c_1)I(c_1) + P(c_2)I(c_2); \quad \text{dado que: } P(c_2) = 1 - P(c_1) = x$$

$$H(S_{binario}) = H(x) = -x log_2(x) - (1-x)\log_2(1-x)$$



Índice Gini

- Sustituye a la entropía
- Resuelve los casos asintóticos de la entropía, en los que habría que aplicar el límite
- Es muy empleada en las bibliotecas de python, aunque ofrecen las dos posibilidades (Gini *vs* Entropy)

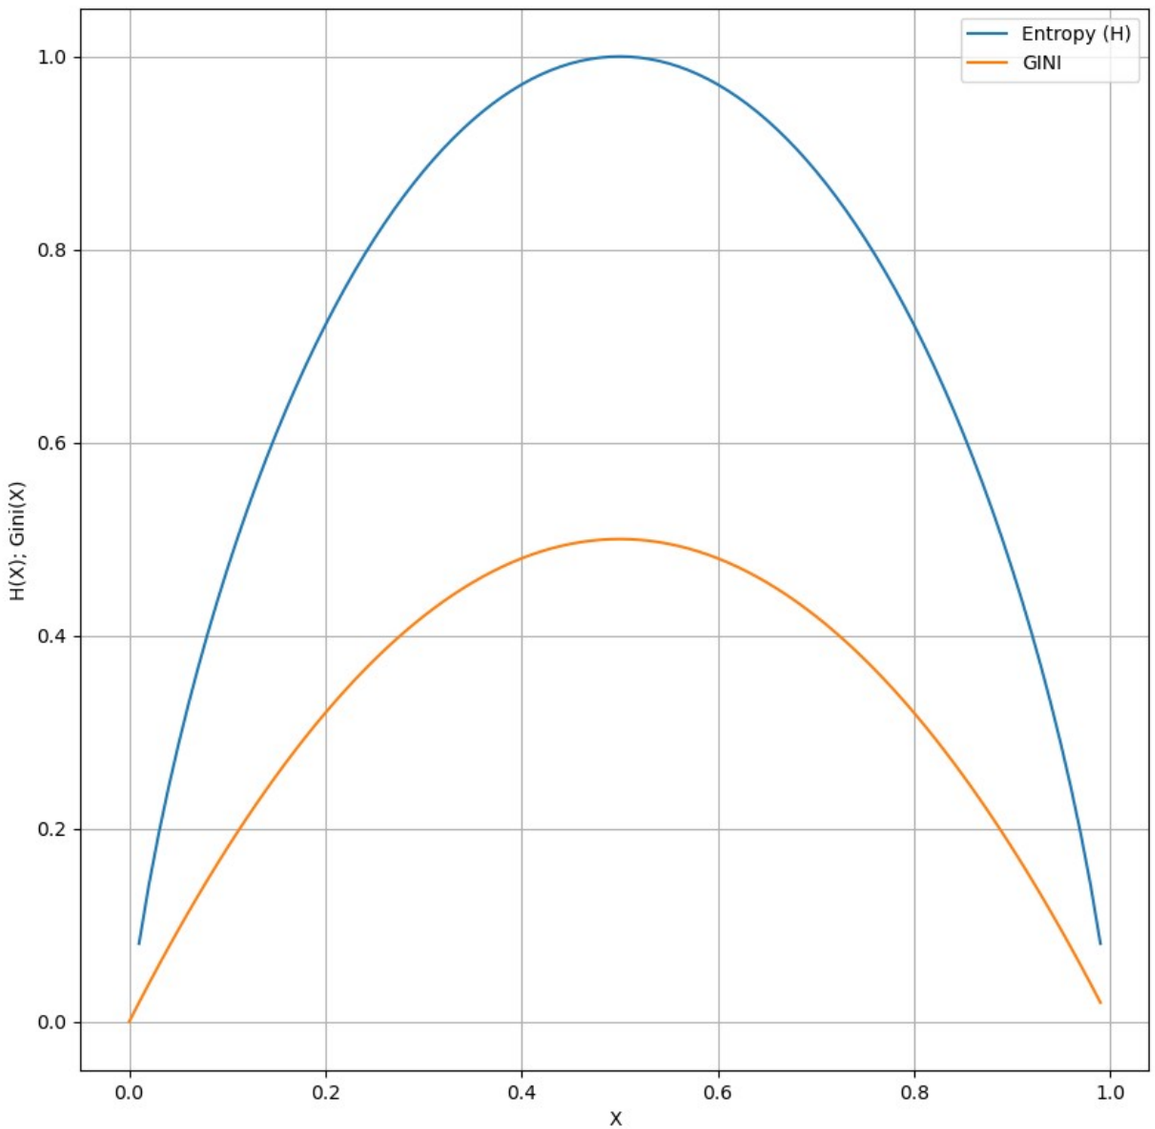
$$Gini(S) = 1 - \sum_{i=1}^{n} p(c_i)^2$$

Índice Gini del Clasificador Binario

$$Gini(S_{binario}) = 1 - P(c_1)^2 - P(c_2)^2$$

Dado que: $P(c_2) = 1 - P(c_1) = x$

$$Gini(S_{binario}) = Gini(x) = 2x(1-x)$$



Ganancia en Información

- Cálculo de la reducción de la entropía por causa de separar los ejemplos basándose en un atributo (A)

$$G(S,A) = H(S) - \sum_{i=1}^{k} \frac{|S_{v_i}|}{|S|} H(S_{v_i}) \qquad |S_{v_i}| = \text{instancias con A(atributo)= } v_i$$

Outlook	Temperature	Humidity	Wind	PlayTennis
Sunny	Hot	High	Weak	**NO**
Sunny	Hot	High	Strong	**NO**
Overcast	Hot	High	Weak	**YES**
Rain	Mild	High	Weak	**YES**
Rain	Cool	Normal	Weak	**YES**
Rain	Cool	Normal	Strong	**NO**
Overcast	Cool	Normal	Strong	**YES**
Sunny	Mild	High	Weak	**NO**
Sunny	Cool	Normal	Weak	**YES**
Rain	Mild	Normal	Weak	**YES**
Sunny	Mild	Normal	Strong	**YES**
Overcast	Mild	High	Strong	**YES**
Overcast	Hot	Normal	Weak	**YES**
Rain	Mild	High	Strong	**NO**

$H(S) = 0.940286$

Outlook	Temperature	Humidity	Wind	PlayTennis
Overcast	Hot	High	Weak	**YES**
Overcast	Cool	Normal	Strong	**YES**
Overcast	Mild	High	Strong	**YES**
Overcast	Hot	Normal	Weak	**YES**
Rain	Mild	High	Weak	**YES**
Rain	Cool	Normal	Weak	**YES**
Rain	Cool	Normal	Strong	**NO**
Rain	Mild	Normal	Weak	**YES**
Rain	Mild	High	Strong	**NO**
Sunny	Hot	High	Weak	**NO**
Sunny	Hot	High	Strong	**NO**
Sunny	Mild	High	Weak	**NO**
Sunny	Cool	Normal	Weak	**YES**
Sunny	Mild	Normal	Strong	**YES**

$H(Overcast) = 0.0 \quad H(Rain) = 0.970951 \quad H(Sunny) = 0.970951$

$G(S, Outlook) = 0.24675$

Entrega

- Hallar la ganancia en información usando la entropía para cada uno de los cuatro atributos de la última tabla (PlayTennis). O si se prefiere, del fichero de datos proporcionado por weka bajo el nombre de “weather nominal”.

- Se hará en un fichero de python (jupyter), en el que se obtendrá en sendos diccionarios:
  - La entropía de cada atributo por separado
  - La ganancia en información respecto a la salida “play”
- Representar ambos diccionarios en un diagrama de barras. Para ello:
  - Import matplotlib.pyplot as plt
  - Plt.bar
- Lo mismo pero aplicando el índice GINI. Si es necesario, construir una función específica
- Representar en una sola gráfica de barras la entropía y el índice GINI

Gráficas entrega

