PRÁCTICA 3: ÁRBOLES DE DECISIÓN – DISCRETIZACIÓN

PARTE I: (Python)

Tome los datos de ejercicio de teoría en el que se discretizaba un valor de la presión. Cree un pequeño script en python que mediante el uso de árboles de decisión, se pueda inferir la cota de digitalización de la presión.

Extender este método a una estratificación por edad de una dataset, alojado en openml, con el ID=1412. Construya una tabla con sólo la edad y el campo objeto de la clasificación. Establezca una digitalización basándose en la Teoría de la Información, usando el árbol de decisión de Sklearn, de entre 6 y 10 cotas (bins).

PARTE II: (WEKA)

En el siguiente enlace del repositorio de la UCI:

http://archive.ics.uci.edu/ml/datasets/Thoracic+Surgery+Data

Se encuentra un ejemplo de clasificación de pacientes relacionados con enfermedades torácicas, en particular, con el riesgo a un año de padecerlas.

Ejecute el código python que se suministra en este repositorio y vuelque en un fichero csv el conjunto de datos correspondiente.

Responder a las siguientes cuestiones:

1. Por qué no se puede aplicar directamente ID3.
2. Pase el algoritmo J48 aplicando el método de retención o Hold-Out. Analice el árbol obtenido sin poda. ¿Se podría prescindir de algún atributo? Si es así, hágalo y compare los resultados de nuevo. Para esta tarea, añadir un código python al ya creado. En él, se hará un pequeño programa, que se alimente de un fichero proveniente de una exportación del árbol en formato texto que proporciona Weka, para detectar los atributos que no se usan. Elimínelos y vuelque el resultado de esto sobre otro fichero csv. Páselo, de nuevo, por el el algoritmo J48 aplicando el método de reserva.

3. Habrá notado que cuando se usa algún atributo numérico, implícitamente se aplica una discretización al plantear las diferentes ramas del árbol a partir de él. ¿Por qué es más eficiente esta técnica que la aplicada en PARTE I?

4. Plantee, entonces, una discretización basada en el punto anterior, aunque no resulte ser binaria, sino en tantos tramos como induzcan los valores usados al formar las ramas del árbol con J48 sin poda (Hold-Out). Introduzca este fichero de nuevo al algoritmo ID3. Compare los resultados con el J48 de 2. Igualmente, para aislar estas cotas, puede construir otro pequeño programa en Python que las localice también en el árbol en formato texto que proporciona Weka.