

Universidad de Valladolid

Universidad de Valladolid

Escuela de Ingeniería Informática

Grado en Ingeniería Informática

Técnicas de Aprendizaje Automático (TAA)

Memoria Práctica Metodología Experimental

Autor
Ángel Antolín Caramazana

Abril 2026

Índice

1. Descripción de los conjuntos de datos **2**
1.1. Soybean 2
1.2. Vote 4

2. Descripción de los algoritmos **5**
2.1. Herramientas a usar 5
2.2. Algoritmos 5

3. Experimentos de 50 instancias **5**

4. Experimento Hold out sin repetición **6**

5. Holdout con repetición **6**
5.1. Tres experimentos 6
5.2. Unión de los 4 (Hold out repetido) 6

6. Validación cruzada sin repetición **7**

7. Validación cruzada con repetición **7**
7.1. Tres experimentos 7
7.2. Unión de los 4 (Validacion cruzada con repeticion) 7

8. Tablas comparativas **8**
8.1. Soybean 8
8.2. Vote 8
8.3. Discusión de resultados 8
8.3.1. Examinar la variación de la tasa de error y la desviación estándar según el método 8
8.3.2. Algoritmos que inducen clasificadores con menor tasa de error . . . 9
8.3.3. Tamaño árboles podados y sin podar (profundidad, número de nodos) 10

9. Preguntas sobre validación cruzada repetida **10**
9.1. ¿Qué tasa de error se obtendría con el método 2? 10
9.2. ¿Cómo espera que varíe la estimación de la varianza con el método 2 frente al método 1? 10
9.3. ¿Y los intervalos de confianza? 11

10. Referencias **11**

1. Descripción de los conjuntos de datos

1.1. Soybean

- **Nombre y origen:** Soybean (Large), originado de la base de datos de enfermedades de la planta de soja de Michalski, guardado en el UCI Machine Learning Repository.
- **Enlace:** `https://archive.ics.uci.edu/dataset/90/soybean+large`
- **Número de instancias:** Cuenta con 683 instancias en total.
- **Número de atributos:** Hay 36 atributos, divididos en 35 atributos predictivos (los cuales son categóricos/nominales y alguno es ordenado, pero ninguno numérico continuo) y un atributo de clase.

Atributos:

1. **date:** Rango: {april, may, june, july, august, september, october}
2. **plant-stand:** Rango: {normal, lt-normal}
3. **precip:** Rango: {lt-norm, norm, gt-norm}
4. **temp:** Rango: {lt-norm, norm, gt-norm}
5. **hail:** Rango: {yes, no}
6. **crop-hist:** Rango: {diff-lst-year, same-lst-yr, same-lst-two-yrs, same-lst-sev-yrs}
7. **area-damaged:** Rango: {scattered, low-areas, upper-areas, whole-field}
8. **severity:** Rango: {minor, pot-severe, severe}
9. **seed-tmt:** Rango: {none, fungicide, other}
10. **germination:** Rango: {90-100, 80-89, lt-80}
11. **plant-growth:** Rango: {norm, abnorm}
12. **leaves:** Rango: {norm, abnorm}
13. **leafspots-halo:** Rango: {absent, yellow-halos, no-yellow-halos}
14. **leafspots-marg:** Rango: {w-s-marg, no-w-s-marg, dna}
15. **leafspot-size:** Rango: {lt-1/8, gt-1/8, dna}
16. **leaf-shread:** Rango: {absent, present}
17. **leaf-malf:** Rango: {absent, present}
18. **leaf-mild:** Rango: {absent, upper-surf, lower-surf}
19. **stem:** Rango: {norm, abnorm}
20. **lodging:** Rango: {yes, no}

21. **stem-cankers:** Rango: {absent, below-soil, above-soil, above-sec-nde}
22. **canker-lesion:** Rango: {dna, brown, dk-brown-blk, tan}
23. **fruiting-bodies:** Rango: {absent, present}
24. **external-decay:** Rango: {absent, firm-and-dry, watery}
25. **mycelium:** Rango: {absent, present}
26. **int-discolor:** Rango: {none, brown, black}
27. **sclerotia:** Rango: {absent, present}
28. **fruit-pods:** Rango: {norm, diseased, few-present, dna}
29. **fruit-spots:** Rango: {absent, colored, brown-w/blk-specks, distort, dna}
30. **seed:** Rango: {norm, abnorm}
31. **mold-growth:** Rango: {absent, present}
32. **seed-discolor:** Rango: {absent, present}
33. **seed-size:** Rango: {norm, lt-norm}
34. **shriveling:** Rango: {absent, present}
35. **roots:** Rango: {norm, rotted, galls-cysts}

Descripción de la clase: El atributo objetivo clasifica las instancias en 19 clases diferentes, correspondiendo a distintas enfermedades que podrían afectar a una planta de soja.

- diaporthe-stem-canker: 20 instancias → 2.93 %
- charcoal-rot: 20 instancias → 2.93 %
- rhizoctonia-root-rot: 20 instancias → 2.93 %
- phytophthora-rot: 88 instancias → 12.88 %
- brown-stem-rot: 44 instancias → 6.44 %
- powdery-mildew: 20 instancias → 2.93 %
- downy-mildew: 20 instancias → 2.93 %
- brown-spot: 92 instancias → 13.47 %
- bacterial-blight: 20 instancias → 2.93 %
- bacterial-pustule: 20 instancias → 2.93 %
- purple-seed-stain: 20 instancias → 2.93 %
- anthracnose: 44 instancias → 6.44 %

- phyllosticta-leaf-spot: 20 instancias → 2.93 %
- alternarialeaf-spot: 91 instancias → 13.32 %
- frog-eye-leaf-spot: 91 instancias → 13.32 %
- diaporthe-pod-&-stem-blight: 15 instancias → 2.20 %
- cyst-nematode: 14 instancias → 2.05 %
- 2-4-d-injury: 16 instancias → 2.34 %
- herbicide-injury: 8 instancias → 1.17 %

1.2. Vote

- **Nombre y origen:** Congressional Voting Records (Vote). Proviene de los registros de votaciones en el congreso de los Estados Unidos de 1984 y se encuentra alojado en el UCI Machine Learning Repository.
- **Enlace:** `https://archive.ics.uci.edu/dataset/105/congressional+voting+records`
- **Número de instancias:** Cuenta con 435 instancias en total.
- **Número de atributos:** Se trata de 17 atributos divididos en 16 atributos predictivos (categóricos/nominales, tratables como booleanos al tratarse de datos de votaciones de leyes con valores de si, no o abstención, no hay numéricos continuos) y un atributo de clase.

Atributos:

1. **handicapped-infants:** Rango: {y, n}
2. **water-project-cost-sharing:** Rango: {y, n}
3. **adoption-of-the-budget-resolution:** Rango: {y, n}
4. **physician-fee-freeze:** Rango: {y, n}
5. **el-salvador-aid:** Rango: {y, n}
6. **religious-groups-in-schools:** Rango: {y, n}
7. **anti-satellite-test-ban:** Rango: {y, n}
8. **aid-to-nicaraguan-contras:** Rango: {y, n}
9. **mx-missile:** Rango: {y, n}
10. **immigration:** Rango: {y, n}
11. **synfuels-corporation-cutback:** Rango: {y, n}
12. **education-spending:** Rango: {y, n}
13. **superfund-right-to-sue:** Rango: {y, n}

14. **crime:** Rango: {y, n}
15. **duty-free-exports:** Rango: {y, n}
16. **export-administration-act-south-africa:** Rango: {y, n}

Descripción de la clase: El atributo objetivo es de tipo binario y clasifica las instancias en 2 clases, indicando la afiliación política del congresista:

- Democrat: 267 instancias → 61.38 %
- Republican: 168 instancias → 38.62 %

2. Descripción de los algoritmos

2.1. Herramientas a usar

Se ha utilizado la herramienta Weka Explorer para poder acceder a los datos aprovechándonos de su interfaz y las herramientas de aprendizaje automático y procesamiento de datos que incluye. En su pestaña de Preprocess accedo a los datos y en Classify puedo acceder a los distintos algoritmos de clasificación que utilizaré.

2.2. Algoritmos

- **J48 con opciones por defecto:** Es la implementación del estándar C4.5 en Weka. Incluye el proceso de poda automática que reduce el sobreajuste.
- **J48 sin poda (Unpruned = true):** Variante del algoritmo anterior que deshabilita la poda automática, permitiendo que el árbol crezca en profundidad hasta clasificar las instancias lo máximo posible, comportándose de manera similar al algoritmo ID3 con discretización de atributos continuos.

3. Experimentos de 50 instancias

El filtro Resample de Weka no deja poner el número de instancias directamente, si no que tengo que calcular que porcentaje del dataset suponen 50 instancias:

- Para Soybean (683 instancias en total): $(50/683) \times 100 = 7{,}3206\,\%$
- Para Vote (435 instancias en total): $(50/435) \times 100 = 11{,}4942\,\%$

La tasa de error la obtengo de Weka en el apartado Incorrectly Classified Instances. Para calcular la desviación estándar y los intervalos, utilizamos la aproximación a la normal:

$$\sigma_{e_S(h)} \approx \sqrt{\frac{e_S(h)(1-e_S(h))}{n}} \tag{1}$$

$$e_S(h) \pm z_N \times \sqrt{\frac{e_S(h)(1-e_S(h))}{n}} \tag{2}$$

Datos	Algoritmo	Tasa error	Desviación estándar	Intervalos (95 %)
Soybean_50	J48	0.5552	0.0197	(0.516, 0.594)
	Sin podar	0.5631	0.0197	(0.524, 0.602)
Vote_50	J48	0.0441	0.0105	(0.023, 0.065)
	Sin podar	0.0701	0.0130	(0.044, 0.096)

4. Experimento Hold out sin repetición

Fórmulas de varianza e intervalos (aproximación normal):

$$var(e_S(h)) \approx \frac{e_S(h)(1 - e_S(h))}{n} \tag{3}$$

Datos	Algoritmo	Tasa error	Varianza	Intervalos (95 %)
Soybean	J48	0.0948	0.000370	(0.0571, 0.1325)
	Sin podar	0.1336	0.000499	(0.0898, 0.1774)
Vote	J48	0.0270	0.000178	(0.0009, 0.0531)
	Sin podar	0.0270	0.000178	(0.0009, 0.0531)

5. Holdout con repetición

5.1. Tres experimentos

Datos	Algoritmo	Tasa de error		
		2	**3**	**4**
Soybean	J48	0.1121	0.1078	0.1379
	Sin podar	0.1164	0.1293	0.1422
Vote	J48	0.0811	0.0541	0.0608
	Sin podar	0.0676	0.0541	0.0608

5.2. Unión de los 4 (Hold out repetido)

Para $k = 4$, calculamos la tasa de error media, la varianza muestral y el intervalo utilizando la t-student con 3 grados de libertad (95 % confianza = 3.182):

$$e(h) = \sum_{i=1}^{k} \frac{e_i(h)}{k} \tag{4}$$

$$S^2_{e(h)} = \frac{1}{k-1} \sum_{i=1}^{k} (e_i(h) - e(h))^2 \tag{5}$$

$$e(h) \pm t_{N,k-1} \times \frac{S_{e(h)}}{\sqrt{k}} \tag{6}$$

Datos	Algoritmo	Tasa error	Varianza	Intervalos (95 %)
Soybean	J48	0.1132	0.0003263	(0.0844, 0.1419)
	Sin podar	0.1304	0.0001156	(0.1133, 0.1475)
Vote	J48	0.0558	0.0004991	(0.0202, 0.0913)
	Sin podar	0.0524	0.0003165	(0.0241, 0.0807)

6. Validación cruzada sin repetición

A partir de los datos proporcionados en el guion de la tasa de aciertos con la semilla uno, realizo los siguientes calculos para obtener la tasa de error de cada particion:

Tasa error = 1 − (Acierto/100).

La tasa de error promedio, varianza muestral y los intervalos se calculan igual que el Hold out con repeticion, la diferencia es que aqui k = 10. Para $k = 10 \rightarrow$ t-student con 9 grados de libertad al 95 % = 2.262.

Datos	Algoritmo	Tasa error	Varianza	Intervalos (95 %)
Soybean	J48	0.0822	0.0001134	(0.0745, 0.0898)
	Sin podar	0.0922	0.00009088	(0.0854, 0.0991)
Vote	J48	0.0343	0.00003272	(0.0302, 0.0384)
	Sin podar	0.0424	0.00007779	(0.0361, 0.0487)

7. Validación cruzada con repetición

7.1. Tres experimentos

Datos	Algoritmo	Tasa de error		
		2	3	4
Soybean	J48	0.0981	0.0908	0.0791
	Sin podar	0.1054	0.1025	0.0893
Vote	J48	0.0322	0.0368	0.0345
	Sin podar	0.0437	0.0414	0.0391

7.2. Unión de los 4 (Validacion cruzada con repeticion)

Al asumir como experimento base cada proceso de validación cruzada, tenemos $R \times k = 4 \times 1 = 4$ en vez de $4 \times 10 = 40$. Aplicamos las fórmulas para $k = 4$, usando t-student con 3 grados de libertad (95 % = 3.182):

$$e(h) = \frac{\sum_{i=1}^{R \times k} e_i(h)}{R \times k} \tag{7}$$

$$S^2_{e(h)} = \frac{1}{R \times k - 1} \sum_{i=1}^{R \times k} (e_i(h) - e(h))^2 \tag{8}$$

$$e(h) \pm t_{N,R \times k-1} \times \frac{S_{e(h)}}{\sqrt{R \times k}} \tag{9}$$

Datos	**Algoritmo**	**Tasa error**	**Varianza**	**Intervalos (95 %)**
Soybean	J48	0.0876	0.00007396	(0.0739, 0.1012)
	Sin podar	0.0973	0.00006088	(0.0849, 0.1098)
Vote	J48	0.0345	0.00000354	(0.0315, 0.0374)
	Sin podar	0.0417	0.00000378	(0.0386, 0.0447)

8. Tablas comparativas

8.1. Soybean

Algoritmo	**Métrica**	**50 instan.**	**Hold out**	**Hold out repet.**	**10-XV**	**4x10-XV**
J48	Error	0.5552	0.0948	0.1132	0.0822	0.0876
	Desviación	0.0197	0.01924	0.01806	0.01065	0.0086
	Intervalos	(0.516, 0.594)	(0.0571, 0.1325)	(0.0844, 0.1419)	(0.0745, 0.0898)	(0.0739, 0.1012)
Sin podar	Error	0.5631	0.1336	0.1304	0.0922	0.0973
	Desviación	0.0197	0.02234	0.01075	0.00953	0.0078
	Intervalos	(0.524, 0.602)	(0.0898, 0.1774)	(0.1133, 0.1475)	(0.0745, 0.0898)	(0.0849, 0.1098)

8.2. Vote

Algoritmo	**Métrica**	**50 instan.**	**Hold out**	**Hold out repet.**	**10-XV**	**4x10-XV**
J48	Error	0.0441	0.0270	0.0558	0.0343	0.0345
	Desviación	0.0105	0.01334	0.02234	0.00572	0.00188
	Intervalos	(0.023, 0.065)	(0.0009, 0.0531)	(0.0202, 0.0913)	(0.0302, 0.0384)	(0.0315, 0.0374)
Sin podar	Error	0.0701	0.0270	0.0524	0.0424	0.0417
	Desviación	0.0130	0.01334	0.01779	0.00882	0.00194
	Intervalos	(0.044, 0.096)	(0.0009, 0.0531)	(0.0241, 0.0807)	(0.0361, 0.0487)	(0.0386, 0.0447)

8.3. Discusión de resultados

8.3.1. Examinar la variación de la tasa de error y la desviación estándar según el método

Soybean:

En el experimento de 50 instancias, la tasa de error es muy alta respecto al resto de métodos (55 %), pues usamos un conjunto muy reducido de datos en comparación a las 683 instancias totales que tiene el dataset.

Con el método de Hold out sin repetición, conseguimos disminuir drásticamente la tasa de error (9.48 % en J48 y 13.36 % sin poda), pero al depender tanto de la partición

aleatoria que se escoja, este método es muy variable, de ahí que la desviación estándar sea la más alta de entre los métodos que utilizan el conjunto de datos completo (0.01924 y 0.02234).

Al realizar el Hold out con repetición, mantenemos la tasa de error parecida pero conseguimos una mejoría en la desviación estándar (0.01806 y 0.01075), pues repetir el proceso mitiga la variabilidad.

Finalmente, la validación cruzada sin repetición consigue mejorar incluso más la tasa de error (8.22 % y 9.22 %), pues utiliza el 90 % de los datos en cada iteración a diferencia del 66 % que usa Hold out. Además, al evitar el solapamiento de los conjuntos de prueba se aprovechan mejor los datos disminuyendo a su vez la desviación estándar.

Por su parte, la Validación cruzada repetida es consistente con las tasas de error, pero la desviación estándar alcanza sus valores mínimos (0.0086 y 0.0078), pues al repetirla conseguimos paliar la influencia de la partición aleatoria, a cambio de un mayor coste computacional que tiene este método.

Vote:

Con el experimento de 50 instancias, el error es bastante más bajo que en Soybean (4.41 % y 7.01 %), pues este conjunto de datos es bastante más sencillo al tener solo 2 clases, 435 instancias y atributos booleanos. Sin embargo, la desviación estándar elevada (0.0105 y 0.0130) revela que sigue siendo una estimación bastante variable.

Al usar Hold out sin repetición, la tasa de error disminuye aún mas (2.70 %), pero la desviación estándar es muy alta (0.01334) en proporción al error tan pequeño. Esto puede indicar que al ser un conjunto de datos más "fácil", depende mucho de la partición aleatoria.

El Hold out con repetición empeora la tasa de error y la desviación estándar llega a su máximo (0.02234). Al solaparse los conjuntos de prueba, el método sigue siendo muy variable.

Por último, la validación cruzada sin repetición, estabiliza la tasa de error (3.43 % y 4.24 %) y reduce la desviación estándar (0.00572 y 0.00882).

Al aplicar después la validación cruzada con repetición, el error no cambia mucho pero la desviación estándar alcanza el mínimo de todo el análisis (0.00188 y 0.00194), demostrando que conseguimos disminuir el efecto de la partición aleatoria y permitiendo definir que la baja tasa de error no es debida al azar de la partición.

8.3.2. Algoritmos que inducen clasificadores con menor tasa de error

Soybean:

J48 con poda (implementación de C4.5) induce el clasificador con menor tasa de error. Observando los datos se aprecia que en todos los métodos de estimación utilizados este consigue una tasa de error menor siempre.

Vote:

Al igual que Soybean, el J48 con poda induce el clasificador con menor tasa de error. En los métodos de estimación más robustos como son la validación cruzada sin/con repetición se observa la mejoría en el error además de la gran ventaja que obtiene en la estimación con solo las 50 instancias en la que, a pesar de la escasez de datos, consigue un clasificador significativamente mejor.

8.3.3. Tamaño árboles podados y sin podar (profundidad, número de nodos)

Soybean:

- **Para el conjunto de 50 instancias:**
  - **J48 con poda:** 22 nodos, 15 hojas y 4 de profundidad.
  - **J48 sin poda:** 33 nodos, 23 hojas y 5 de profundidad.
- **Para el modelo base:**
  - **J48 con poda:** 93 nodos, 61 hojas y 9 de profundidad.
  - **J48 sin poda:** 175 nodos, 121 hojas y profundidad mayor a 10.

Vote:

- **Para el conjunto de 50 instancias:**
  - **J48 con poda:** 3 nodos, 2 hojas y 1 de profundidad.
  - **J48 sin poda:** 5 nodos, 3 hojas y 2 de profundidad.
- **Para el modelo base:**
  - **J48 con poda:** 11 nodos, 6 hojas y 4 de profundidad.
  - **J48 sin poda:** 37 nodos, 19 hojas y 7 de profundidad.

9. Preguntas sobre validación cruzada repetida

9.1. ¿Qué tasa de error se obtendría con el método 2?

Como la fórmula de la tasa de error del Método 2

$$e(h) = \frac{\sum_{i=1}^{R \times k} e_i(h)}{R \times k}$$

calcula el promedio sobre el total de capas individuales (40 en este caso), matemáticamente la media global de estas 40 capas es idéntica a la media de los 4 resultados globales utilizados en el método 1; es decir, las tasas de error del método 1 y método 2 son iguales en todos los casos (0.0876 y 0.0973 para Soybean y 0.0345 y 0.0417 para Vote).

9.2. ¿Cómo espera que varíe la estimación de la varianza con el método 2 frente al método 1?

Al tratarse de repeticiones que no son totalmente independientes, añadido a que los conjuntos de entrenamiento se solapan entre ellos en cada repetición, esto hace que el método 2 sea ligeramente optimista produciendo que la estimación de la varianza disminuya.

9.3. ¿Y los intervalos de confianza?

Al usar 39 grados de libertad en vez de 3, la distribución t-student se aproximaría más a la distribución normal, multiplicando por un valor t más pequeño y dividiendo por un denominador más grande, disminuiría el margen de error respecto al método 1 produciendo un intervalo más estrecho y aparentemente más preciso.

10. Referencias

- Michalski, R. S. Soybean (Large). UCI Machine Learning Repository. Recuperado de: `https://archive.ics.uci.edu/dataset/90/soybean+large`
- Congressional Voting Records (Vote). UCI Machine Learning Repository. Recuperado de: `https://archive.ics.uci.edu/dataset/105/congressional+voting+records`
- Material teórico de la asignatura: Metodología experimental para la creación y evaluación de clasificadores.
- Apoyo para facilitación de cálculos y redacción de la herramienta de IA Generativa Gemini.